~/research/proposal/main.py

```python
# Proposal Mini-Riset NLP Lanjut
def evaluate_ner():
    return """
```

Evaluasi Fair Open-Type Named Entity Recognition dengan GLiNER pada CleanCoNLL

> Analisis Dampak Label Noise pada CoNLL-03

```python
    """

if __name__ == "__main__":
    execute_proposal(author="Mahasiswa Magister")
```

Exception: Ketidakadilan dalam Evaluasi NER Klasik

Akar Masalah: Label Noise

```
// CoNLL-03 Dataset (Benchmark Klasik)
error_rate = 5.38%
status = "Mengandung banyak kesalahan anotasi manusia"
```

> **CoNLL-03** adalah benchmark paling populer untuk evaluasi NER sejak tahun 2003.

> Penelitian terbaru (Reiss et al., 2020) menemukan bahwa dataset ini memiliki **tingkat kesalahan anotasi (label noise) sebesar 5.38%**.

> Kesalahan meliputi: inkonsistensi batas entitas (boundary errors), salah klasifikasi tipe (type errors), dan entitas yang terlewat.

Dampak: Unfair Evaluation

```
// Skenario Evaluasi yang Tidak Adil
model_prediction = "Benar secara semantik"
gold_standard = "Salah anotasi"
result = False Negative (Model disalahkan)
```

> Model modern yang canggih (seperti **GLiNER**) sering kali memprediksi entitas dengan benar secara semantik.

> Namun, karena *ground truth* (kunci jawaban) di CoNLL-03 salah, **model tersebut dihukum (penalized)** dan skor F1-nya turun.

> Akibatnya, kita **tidak bisa mengukur performa asli** dari model open-type NER secara adil dan akurat.

SELECT * FROM Literature Review & Positioning

Tabel Posisi Penelitian

Penelitian	Fokus Utama	Model NER	Dataset	Error Analysis	Keterbatasan
Reiss et al. (2020)	Identifikasi label noise …	RoBERTa	CoNLL-03	✓ Ya	Hanya model spes…
Wang & Mueller (2022)	Evaluasi NER pada dataset…	BERT, BiLSTM	CoNLL-03 (Noisy)	✗ Terbatas	Tidak menggunaka…
Zaratiana et al. (20…	Pengembangan model open-t…	GLiNER	Pile-NER, dll.	✗ Terbatas	Evaluasi masih m…
Rücker & Akbik (2023…	Pembuatan dataset NER beb…	FLERT	CleanCoNLL	✓ Ya	Belum dievaluasi…
Penelitian Ini	**Fair evaluation & dampak …**	**GLiNER (Open-Typ…**	**CoNLL-03 & Clean…**	**✓ Mendalam**	**-**

const Research Questions & Objectives

Research Questions (RQ)

```
{
  "RQ1": {
    "type": "Quantitative",
    "query": "Bagaimana perbandingan performa model GLiNER pada dataset CoNLL-03 (noisy) dibandingkan dengan CleanCoNLL (clean)?"
  },
  "RQ2": {
    "type": "Qualitative",
    "query": "Bagaimana pergeseran jenis kesalahan (Boundary Error vs Type Error) yang terjadi setelah label noise dibersihkan?"
  }
}
```

Research Objectives (OBJ)

```
[
  {
    "id": 1,
    "target": "Mengukur dampak kuantitatif label noise terhadap metrik evaluasi (F1-score, Precision, Recall) pada model open-type NER."
  },
  {
    "id": 2,
    "target": "Menganalisis secara kualitatif pergeseran error untuk membuktikan bahwa evaluasi pada dataset bernoise sering kali menghukum model yang sebenarnya memprediksi dengan benar."
  }
]
```

import Metodologi: Dataset, Model, dan Metrik

1. Dataset

```
{
  "baseline": {
    "name": "CoNLL-03",
    "status": "Noisy",
    "error_rate": 5.38
  },
  "ground_truth": {
    "name": "CleanCoNLL",
    "status": "Cleaned",
    "method": "Manual re-annotation"
  },
  "entity_types": [
    "PER"
    "ORG"
    "LOC"
    "MISC"
  ]
}
```

2. Model

```
{
  "architecture": {
    "name": "GLiNER",
    "type": "Open-Type NER",
    "base": "Bidirectional Transformer"
  },
  "capabilities": [
    "Zero-shot inference",
    "Arbitrary entity detection",
    "Token-level classification"
  ],
  "advantages": {
    "flexibility": true,
    "sota_performance": true
  }
}
```

3. Metrik Evaluasi

```
{
  "quantitative": [
    "Precision",
    "Recall",
    "Micro F1-Score"
  ],
  "qualitative": {
    "name": "Error Analysis",
    "types": [
    "Boundary Error",
    "Type Error",
    "Missed Entity"
    ]
  },
  "comparison": "CoNLL-03 vs
  CleanCoNLL"
}
```

Config: Skenario Eksperimen & Parameter Settings

Skenario Eksperimen Utama

- >> **Tujuan:** Mengukur dampak label noise terhadap performa model open-type NER secara adil.
- >> **Metode:** Melakukan *Zero-Shot Inference* menggunakan model GLiNER yang sama pada dua dataset berbeda.
- >> **Perbandingan:** Performa di CoNLL-03 (Noisy) vs CleanCoNLL (Clean).
- >> **Analisis:** Membandingkan metrik kuantitatif (F1-score) dan melakukan error analysis kualitatif.

GLiNER Model → Inference → CoNLL-03 & CleanCoNLL

configs/default.yaml

```yaml
# Model Configuration
model:
  name: "knowledgator/gliner-multitask-large-v0.5"
  type: "open-type-ner"

# Inference Parameters
inference:
  threshold: 0.5
  batch_size: 8
  max_length: 512

# Target Entities (CoNLL-03)
labels:   - "person"   - "organization"
# Reproducibility
environment:
  seed: 42
```

Output: Expected Outcomes & Kontribusi Penelitian

Hasil yang Diharapkan

> **Kuantitatif:** Peningkatan skor F1, Precision, dan Recall GLiNER pada CleanCoNLL dibandingkan dengan CoNLL-03.

> **Kualitatif (Error Analysis):** Pergeseran jenis kesalahan yang signifikan.

```
# Hipotesis Error Shift
Type Errors menurun di CleanCoNLL.
Boundary Errors mungkin tetap ada.
```

> **Noise Attribution:** Persentase pasti dari "kesalahan model" di CoNLL-03 yang sebenarnya adalah kesalahan dataset.

Kontribusi Penelitian

> **Fair Evaluation Framework:** Menyediakan kerangka kerja evaluasi yang lebih adil untuk model open-type NER modern.

> **Empirical Evidence:** Bukti empiris tentang seberapa besar label noise pada benchmark klasik mendistorsi performa model SOTA.

> **Actionable Insights:** Panduan bagi praktisi NLP:

```
# Rekomendasi Praktis
use CleanCoNLL   avoid CoNLL-03
```

> **Meta-Evaluation:** Berkontribusi pada literatur yang mengevaluasi cara kita mengevaluasi model.

@optional Opsi Penguatan Riset

1. Uji Signifikansi Statistik

Rigoritas Metodologi

Menggunakan **McNemar's test** atau **Bootstrap resampling** untuk membuktikan bahwa perbedaan performa GLiNER di CoNLL-03 vs CleanCoNLL benar-benar signifikan secara statistik, bukan karena kebetulan.

2. Variasi Ukuran Model (Ablation)

Analisis Sensitivitas

Membandingkan performa varian GLiNER: **Small (44M)**, **Medium (86M)**, dan **Large (304M)**. Tujuannya untuk menganalisis apakah model yang lebih besar lebih kebal terhadap label noise, atau justru lebih mudah "tertipu" oleh anomali.

3. Zero-shot vs Fine-tuned

Implikasi Praktis

Melakukan fine-tuning pada base model (urchade/gliner_medium-v2.1) menggunakan CleanCoNLL vs CoNLL-03. Tujuannya untuk melihat apakah melatih model dengan data yang bersih menghasilkan performa dunia nyata yang lebih baik.

./execute Timeline & Kesimpulan

>_ Execution Timeline

$ [Minggu 1-2] Setup environment, instalasi dependensi, dan persiapan dataset (CoNLL-03 & CleanCoNLL).

$ [Minggu 3-4] Eksekusi zero-shot GLiNER pada dataset dan pengumpulan metrik.

$ [Minggu 5-6] Analisis kualitatif dan eksperimen lanjutan (Ablation/Fine-tuning).

$ [Minggu 7-8] Penyusunan laporan akhir, visualisasi, dan persiapan presentasi.

> Status: Ready to start

🏁 Kesimpulan Proposal

Label noise pada benchmark klasik seperti CoNLL-03 menyebabkan **evaluasi yang tidak adil (unfair evaluation)** bagi model open-type NER modern seperti GLiNER.

Dengan menggunakan **CleanCoNLL** sebagai *ground truth* yang lebih reliabel, penelitian ini akan mengungkap performa asli model dan mengidentifikasi jenis kesalahan secara akurat.

Hasil riset ini akan memberikan **bukti empiris** dan **panduan praktis** bagi komunitas NLP dalam mengevaluasi model NER.

```
return {
  "status": "Proposal Approved",
  "readiness": "100%",
  "impact": "High"
}
```

Referensi Utama


```
@inproceedings{rucker-akbik-2023-cleanconll, title={CleanCoNLL: A Nearly Noise-Free Named Entity Recognition Dataset}, author={Rücker, S.; Akbik, A.}, year={2023} }
```

```
@article{zaratiana-etal-2023-gliner, title={GLiNER: Generalist Model for NER using Bidirectional Transformer}, author={Zaratiana, U.; Tomeh, N.; Holat, P.}, year={2023} }
```

```
@inproceedings{reiss-etal-2020-identifying, title={Identifying Incorrect Labels in the CoNLL-03 Corpus}, author={Reiss, F. et al.}, year={2020} }
```


✅ Terima Kasih. EOF.