ubuntu@rusydi:~$ ./run_proposal.sh

Evaluasi Fair Open-Type Named Entity Recognition dengan GLiNER pada CleanCoNLL

- Analisis Dampak Label Noise pada CoNLL-03
+ Menuju Evaluasi Model NLP yang Lebih Reliabel

AUTHOR Muhammad Rusydi Al Affan - 2506575932

DATE Maret 2026

STATUS [READY] Menunggu eksekusi

Issue #1: Mengapa Fair Evaluation dalam NER Masih Menjadi Tantangan?

CoNLL-03 adalah benchmark NER paling terkenal dan banyak digunakan dalam komunitas NLP selama lebih dari dua dekade.

Namun, penelitian terbaru mengungkapkan masalah kritis yang sering diabaikan, membuat evaluasi model modern menjadi bias dan tidak akurat.

CRITICAL IMPACT

Ketika model state-of-the-art dievaluasi, 47% dari prediksi yang dianggap "salah" sebenarnya secara semantik benar, tetapi tidak sesuai dengan label CoNLL-03 yang bermasalah.

conll03_issues.log — 3 errors found

```
1   NOISE   Noise dalam Anotasi
-   Reiss et al. (2020) menemukan 3.8% dari semua label salah.
-   Tingkat error mencapai 7.5% pada test split.
4
5   INCONSISTENCY   Inkonsistensi Anotasi
-   Wang et al. (2019) menemukan kesalahan dalam 5.4% kalimat.
-   Entitas yang sama sering diberi label berbeda (misal: nama tim olahraga, kementerian).
8
9   SEGMENTATION   Kesalahan Segmentasi
-   Batas token, entity, dan kalimat sering kali tidak konsisten.
11
12  ⚠ Kesimpulan Evaluasi:
13  Model SOTA mencapai F1-score yang sebanding dengan tingkat noise.
14  Sulit membedakan kelemahan model vs anotasi yang salah.
```

Patch #1: Menuju Evaluasi yang Lebih Adil: CleanCoNLL

dataset_update.diff +4 additions

```
1   // Karakteristik CleanCoNLL sebagai Ground Truth
+   RELABELING   Perbaikan Komprehensif
+   Memperbaiki 7.0% dari semua label di CoNLL-03 melalui proses cermat.

4
+   LINKING   Entity Linking Integration
+   Menambahkan layer anotasi yang menghubungkan entitas ke Wikipedia.

7
+   CONSISTENCY   Cross-Checking Iteratif
+   Menggunakan 3 rounds cross-checking dengan model SOTA.

10
+   EXPLAIN   Explainability
+   Alasan di balik setiap label NER lebih transparan untuk inspeksi.
```

$ ./evaluate --mode=fair --model=GLiNER

Positioning Penelitian

Dengan menjalankan GLiNER pada kedua dataset (CoNLL-03 original dan CleanCoNLL), penelitian ini akan:

- **Mengidentifikasi perbedaan performa** yang signifikan secara kuantitatif.
- **Menganalisis jenis kesalahan** yang bergeser antara dua evaluasi.
- **Membedakan sumber error:** kelemahan model versus kualitas label dataset.
- **Memberikan insight valid** tentang performa sesungguhnya dari model NER modern.

Model: GLiNER (Generalist Model untuk Open-Type NER)

Mengapa GLiNER?

GLiNER adalah model NER generalis yang dirancang untuk mengidentifikasi tipe entitas apapun tanpa perlu fine-tuning pada setiap dataset spesifik.

Relevansi untuk Penelitian

GLiNER adalah pilihan ideal untuk evaluasi fair karena:

- **Compact & Reproducible:** Model yang efisien memungkinkan eksperimen yang ekstensif.
- **Zero-Shot Capability:** Memungkinkan evaluasi murni tanpa bias dari fine-tuning pada dataset target.
- **Strong Baseline:** Performa yang kuat memberikan dasar yang solid untuk analisis error.

gliner_architecture.json JSON

```json
{
    "model_name": "GLiNER",
    "architecture": {
        "backbone": "Bidirectional LMs (BERT/DeBERTa)",
        // Bukan LLM besar yang mahal & lambat
        "approach": "Matching problem dalam latent space",
        "input_format": "[Entity Types] + [SEP] + [Text Input]",
        "output": "Matching scores via dot product & sigmoid"
    },
    "advantages": {
        "efficiency": "50M-300M params (vs LLMs 7B-13B)",
        "speed": "Pemrosesan paralel (bukan sequential token gen)",
        "zero_shot_performance": true,
        // Mengungguli ChatGPT & fine-tuned LLMs
        "multilingual": true
    }
}
```

SELECT * FROM Literature Review & Posisi Penelitian

Tabel Posisi Penelitian

Penelitian	Fokus Utama	Model NER	Dataset	Error Analysis	Keterbatasan
Reiss et al. (2020)	Identifikasi label noise di CoNLL-03	RoBERTa	CoNLL-03	✓ Ya	Hanya model spesifik, belum ada dataset bersih
Wang & Mueller (2022)	Evaluasi NER pada dataset bernoise	BERT, BiLSTM	CoNLL-03 (Noisy)	✗ Terbatas	Tidak menggunakan model open-type modern
Zaratiana et al. (2023) [GLiNER]	Pengembangan model open-type NER	GLiNER	Pile-NER, dll.	✗ Terbatas	Evaluasi masih menggunakan benchmark bernoise
Rücker & Akbik (2023) [CleanCoNLL]	Pembuatan dataset NER bebas noise	FLERT	CleanCoNLL	✓ Ya	Belum dievaluasi dengan model open-type SOTA
Penelitian Ini	**Fair evaluation & dampak label noise**	**GLiNER (Open-Type)**	**CoNLL-03 & CleanCoNLL**	✓ **Mendalam**	-

Query: Pertanyaan Penelitian yang Mengarahkan Investigasi

research_questions.sh — 4 queries

$ RQ1: Analisis Performa

Bagaimana perubahan performa GLiNER antara CleanCoNLL dan CoNLL-03?

> Apakah F1-score meningkat, dan berapa perbedaan precision/recall?

$ RQ2: Analisis Kesalahan

Jenis kesalahan apa yang bergeser antar dataset?

> Apakah pola error berubah pada dataset yang lebih bersih?

$ RQ3: Dampak Label Noise

Seberapa besar kontribusi label noise pada underestimation?

> Berapa proporsi prediksi yang semantik benar tapi ditandai salah?

$ RQ4: Implikasi Praktis

Apa implikasi fair evaluation untuk penggunaan NER?

> Bagaimana rekomendasi untuk benchmarking NER di masa depan?

Objectives

01 Melakukan **evaluasi empiris** yang ketat terhadap GLiNER pada kedua dataset.

02 Melakukan **error analysis** yang mendalam untuk mengidentifikasi pola kesalahan.

03 Memberikan **bukti kuantitatif** tentang dampak label noise pada evaluasi NER.

04 Menghasilkan **insights yang actionable** untuk penelitian dan praktik NER.

Config: Desain Metodologi: Dataset, Model, dan Metrik Evaluasi

dataset_config.yaml

dataset_1: CoNLL-03 (Original)

- Corpus klasik untuk NER — 4 types (PER, LOC, ORG, MISC)
- Splits: Train ~14,987 • Dev ~3,466 • Test ~3,684
- Status: Mengandung noise & inkonsistensi

dataset_2: CleanCoNLL

- Versi yang direlabel & integrasi entity linking (Wikipedia/Wikidata)
- ~7.0% label corrections • cross-checking iteratif
- Status: Cleaned & Consistent

model_config.yaml

model_name: GLiNER-L (Large)

- Variant terbesar — 300M parameters • Backbone: DeBERTa-v3

training_data: Pile-NER

- 44,889 passages • 240k entity spans • 13k distinct types

inference_mode: Zero-shot

- Evaluasi tanpa fine-tuning — memastikan fairness

metrics_config.yaml

metrics_utama:

- F1-Score (harmonic mean), Precision, Recall, Accuracy
- Evaluasi per-entity: F1/Prec/Rec untuk PER, LOC, ORG, MISC

error_analysis_metrics:

- False Positives/Negatives • Boundary Errors • Type Errors

Config: Skenario Eksperimen & Parameter Settings

Tujuan Eksperimen

Mengevaluasi performa model open-type NER (GLiNER) dan menganalisis pergeseran jenis kesalahan (error shift) akibat label noise dengan membandingkan hasil inferensi pada dataset bernoise (CoNLL-03) dan dataset bersih (CleanCoNLL).

Metode yang Dibandingkan

- **Model Utama:** knowledgator/gliner-multitask-large-v0.5 (Zero-shot inference)
- **Baseline Evaluation:** Evaluasi pada CoNLL-03 test set (Original, Noisy)
- **Target Evaluation:** Evaluasi pada CleanCoNLL test set (Cleaned, Ground Truth)
- **Entity Types:** person, organization, location, miscellaneous (PER, ORG, LOC, MISC)

Parameter Settings

- **Confidence Threshold:** 0.5 (default GLiNER)
- **Batch Size (Inference):** 8
- **Max Sequence Length:** 512 tokens
- **Random Seed:** 42 (reproducibility)
- **Hardware:** NVIDIA GPU (T4/V100 recommended)

Output: Kontribusi Penelitian & Hasil yang Diharapkan

Hasil yang Diharapkan

- **Quantitative:** Performa GLiNER pada CoNLL-03 vs CleanCoNLL dengan perbandingan F1-score, Precision, Recall
- **Error Analysis:** Breakdown jenis kesalahan (False Positives, False Negatives) per entity type
- **Noise Attribution:** Persentase improvement yang berasal dari pembersihan label vs kualitas model
- **Ablation Results:** Performa model size variants (Small, Medium, Large) terhadap label noise
- **Fine-tuning Impact:** Perbandingan zero-shot vs fine-tuned pada CleanCoNLL

Novelty & Perbedaan dengan Penelitian Sebelumnya

- **vs Reiss et al. (2020):** Kami menggunakan CleanCoNLL sebagai ground truth, bukan hanya mengidentifikasi noise.
- **vs Wang & Mueller (2022):** Kami mengevaluasi dengan model open-type SOTA modern (GLiNER), bukan BERT/BiLSTM.
- **vs GLiNER paper:** Evaluasi yang lebih fair menggunakan CleanCoNLL, bukan hanya CoNLL-03 bernoise.
- **vs CleanCoNLL paper:** Mengevaluasi CleanCoNLL dengan model open-type generalist yang belum pernah dievaluasi sebelumnya.
- **Kombinasi unik:** GLiNER + CleanCoNLL + Error Analysis mendalam = Fair Evaluation Framework yang novel.

ENV: Mengapa Penelitian Ini Penting: Positioning dalam Landscape NLP

Benchmark Quality Crisis

- Banyak benchmark NLP diketahui mengandung noise dan inkonsistensi.
- CoNLL-03 tetap digunakan meskipun bermasalah karena kurangnya alternatif.
- CleanCoNLL menawarkan solusi tetapi belum banyak dievaluasi sistematis.

Fair Evaluation Movement

- Komunitas NLP semakin sadar pentingnya fair evaluation.
- Gerakan untuk membuat benchmark yang lebih berkualitas tinggi.
- Penelitian ini memberikan bukti empiris untuk mendukung gerakan ini.

Open-Type NER Trend

- Open-type NER (ekstraksi entitas arbitrary) semakin penting.
- GLiNER mewakili generasi baru model NER yang fleksibel.
- Evaluasi yang fair dari model-model ini menjadi sangat krusial.

Positioning Penelitian

BRIDGE Menghubungkan CleanCoNLL (resource) dan GLiNER (model) untuk evaluasi yang lebih fair.

ADVOCATE Mempromosikan pentingnya fair evaluation dalam komunitas NLP.

EVIDENCE Memberikan bukti empiris konkret tentang dampak label noise pada evaluasi.

Relevance untuk Dunia Nyata

- Insights dari penelitian ini membantu praktisi NLP dalam **memilih model yang tepat**.
- Membantu dalam **menginterpretasi hasil evaluasi** dengan lebih akurat dan tidak bias.
- Mendorong adopsi **best practices** yang lebih baik dalam benchmarking NLP di industri.

Add-ons: Opsi Penguatan Riset

// Tiga elemen tambahan untuk meningkatkan rigoritas metodologi dan memastikan kualitas riset level Magister (S2) yang solid.

1. Uji Signifikansi Statistik (Statistical Significance Testing)

Rigoritas Metodologi

Jangan hanya melaporkan kenaikan F1-score. Gunakan uji statistik (misalnya **McNemar's test** atau **Bootstrap resampling**) untuk membuktikan bahwa perbedaan performa GLiNER di CoNLL-03 vs CleanCoNLL benar-benar signifikan secara statistik, bukan karena kebetulan (random variance).

2. Variasi Ukuran Model (Model Size Ablation)

Analisis Sensitivitas

Bandingkan beberapa varian ukuran GLiNER (**Small, Base, Large**). Analisis apakah *label noise* lebih berdampak pada model kecil dibandingkan model besar. Apakah model besar lebih kebal terhadap noise (robust), atau justru lebih mudah "tertipu" oleh anomali pada dataset?

3. Zero-shot vs Fine-tuned (Generalization Test)

Implikasi Praktis

Evaluasi GLiNER secara **zero-shot** di kedua dataset. Jika waktu memungkinkan, coba **fine-tune** GLiNER di CleanCoNLL dan lihat apakah performanya di dunia nyata (atau dataset *out-of-domain*) menjadi lebih baik dibandingkan jika di-fine-tune menggunakan CoNLL-03 yang bernoise.

Plan: Rencana Eksekusi & Kesimpulan

project_timeline.csv

FASE	AKTIVITAS
Fase 1	Setup environment dan persiapan dataset
Fase 2	Implementasi evaluasi GLiNER pada kedua dataset
Fase 3	Error analysis dan investigasi label noise
Fase 4	Analisis mendalam dan interpretasi results
Fase 5	Penulisan paper dan dokumentasi

Key Deliverables

- Evaluasi GLiNER pada CoNLL-03 & CleanCoNLL (metrics)
- Error analysis report dengan visualisasi
- Paper mini riset (8 halaman, ACL)
- Presentasi hasil penelitian

Kesimpulan Proposal

Penelitian ini mengusulkan evaluasi yang lebih adil untuk open-type NER menggunakan **GLiNER** dan **CleanCoNLL** sebagai ground truth yang lebih reliabel.

Diharapkan memberi insights tentang performa model NER dan mendorong evaluasi yang lebih adil.

Import: Referensi Penelitian

// CLEANCONLL PAPER

Rücker, S., & Akbik, A. (2023). *"CleanCoNLL: A Nearly Noise-Free Named Entity Recognition Dataset."* Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 8628–8645.

// GLINER PAPER

Zaratiana, U., Tomeh, N., Holat, P., & Charnois, T. (2023). *"GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer."*

// RELATED WORK ON CONLL-03 QUALITY

Reiss, F., Xu, B., Mao, S., Christodorescu, M., Sankaranarayanan, R., & Tiwari, A. (2020). *"Identifying Incorrect Labels in the CoNLL-2003 Benchmark Corpus."* arXiv preprint arXiv:2003.06064.

Wang, X., & Mueller, K. (2022). *"Evaluating Named Entity Recognition on Noisy Datasets."*

// OPEN-TYPE NER REFERENCES

Zhou, W., Jiang, N., Zhang, L., & Cui, L. (2023). *"Towards Generalist Models for Named Entity Recognition."*

Sainz, O., Rigau, G., & Agirre, E. (2023). *"GoLLIE: Annotation Guidelines and a Living Benchmark for Structured Extraction from Large Language Models."*